

Ejercicios — Evaluación de clasificadores

Machine Learning

Notación

La de la asignatura. Sobre n observaciones con etiqueta $y_i \in \{0, 1\}$ y puntaje $s_i \in [0, 1]$, un umbral τ produce la clase predicha $\hat{y}_i = \mathbb{1}\{s_i \geq \tau\}$ y con ella la matriz de confusión de celdas TP , FP , FN y TN . Se escribe $P = TP + FN$ y $N = FP + TN$ para los positivos y negativos **reales**, y $\pi = P/n$ para la prevalencia de la clase positiva. TPR y FPR designan las tasas de verdaderos y de falsos positivos, y C_{TP} , C_{FP} , C_{FN} , C_{TN} los costos asociados a cada casillero.

1. Leer una matriz de confusión

Un detector de fallas de máquina se evalúa sobre **500 turnos de producción**, de los cuales **40 terminaron en falla**. El sistema marcó **60 turnos** como riesgosos y acertó en **28** de ellos.

- Reconstruir las cuatro celdas de la matriz de confusión.
- Calcular accuracy, precision, recall y especificidad.
- Calcular F_1 y F_2 . Justificar cuál de las dos corresponde reportar, sabiendo que una parada no anticipada detiene la línea durante ocho horas y que una revisión preventiva innecesaria consume veinte minutos de un técnico.
- Calcular el accuracy de la regla «ningún turno falla» y comparar con el del inciso (b). Indicar qué se concluye del resultado.
- El proveedor del sistema propone reemplazar la métrica reportada por la especificidad, argumentando que es la más alta de todas. Responder si el argumento es admisible.

2. Qué métrica corresponde

Para cada situación, indicar **qué métrica o par de métricas** conviene reportar y **cuál sería engañosa**, justificando en una o dos frases. En todos los casos la clase positiva es el evento nombrado.

- Un tamizaje poblacional de una enfermedad de prevalencia 0,003, cuyo resultado positivo deriva en un estudio confirmatorio barato e inocuo, y cuyo diagnóstico tardío es muy grave.
- Un filtro que desvía correo no deseado a una carpeta que el usuario no revisa.
- Un modelo de deserción de clientes cuya salida alimenta una campaña de retención con presupuesto para contactar a 500 clientes por mes, sobre una cartera de 80 000.
- Un clasificador de imágenes de tres especies de plantas, con 2000, 1800 y 90 ejemplares respectivamente, destinado a un inventario ecológico donde la especie rara es la de interés.
- Dos equipos entregan modelos para el mismo problema y hay que elegir uno **antes** de definir el umbral de operación.

3. Las dos curvas, a mano

Un clasificador produce, sobre doce observaciones, los siguientes puntajes ya ordenados de mayor a menor:

k	1	2	3	4	5	6	7	8	9	10	11	12
s	0,95	0,88	0,82	0,74	0,66	0,59	0,51	0,44	0,33	0,27	0,18	0,07
y	1	0	1	1	0	1	0	0	1	0	0	0

- Completar la tabla del barrido: para cada k , las cuatro celdas de la matriz de confusión que resulta de clasificar como positivas exactamente las k primeras observaciones, y con ellas TPR, FPR y precision.
- Dibujar la curva ROC. Indicar cuánto mide cada paso vertical y cada paso horizontal, y por qué.
- Calcular el AUC **contando pares**: sobre los $P \cdot N$ pares formados por un positivo y un negativo, cuántos están bien ordenados.
- Verificar que el resultado de (c) coincide con el área bajo la curva escalonada dibujada en (b).
- Dibujar la curva precision-recall y calcular la average precision. Indicar dónde está su línea base.
- Un segundo clasificador, sobre las mismas doce observaciones, produce puntajes distintos pero **el mismo ordenamiento**. Indicar cuáles de las cantidades calculadas cambian.

4. Cuatro resultados que conviene tener derivados

- Partiendo de la definición de F_1 como media armónica de precision y recall, deducir $F_1 = \frac{2TP}{2TP + FP + FN}$ y explicar qué consecuencia tiene la ausencia de TN en esa expresión.
- Escribir F_β como media armónica **ponderada** de precision y recall, y exhibir los pesos. Justificar a partir de ellos la afirmación de que «el recall pesa β^2 veces lo que pesa la precision».
- Demostrar que la curva precision-recall de un clasificador que asigna puntajes independientes de la clase es la recta horizontal precision = π .
- Partiendo de $TP = n\pi$ TPR y $FP = n(1 - \pi)$ FPR, deducir

$$\text{precision} = \frac{\pi \text{TPR}}{\pi \text{TPR} + (1 - \pi) \text{FPR}}$$

y explicar, a partir de esa expresión, por qué la curva ROC no se modifica al cambiar la proporción de positivos de la población y la curva PR sí.

5. Dónde cortar

- Deducir el umbral τ^* que minimiza el costo esperado, escribiendo el costo esperado de cada una de las dos decisiones y comparándolos. No suponer que acertar tenga costo nulo.
- Verificar que con $C_{TP} = C_{TN} = 0$ la expresión se reduce a $\tau^* = C_{FP}/(C_{FP} + C_{FN})$, e indicar bajo qué condición vale 0,5.
- Calcular τ^* en los tres escenarios siguientes, todos con $C_{TP} = C_{TN} = 0$:

Escenario	C_{FN}	C_{FP}
Detección de fraude con tarjeta	900	25
Filtro de correo no deseado	2	40
Tamizaje clínico	50 000	180

- Explicar por qué multiplicar los dos costos por diez no modifica τ^* , y qué cantidad sí lo determina.
- Un analista fija τ buscando el mínimo de la curva de costo sobre el conjunto de prueba, y reporta el costo alcanzado en ese punto como estimación del costo en producción. Indicar qué hay de incorrecto en el procedimiento y cómo se corrige.
- La deducción de (a) supone una propiedad de $\hat{p}$ que ninguna de las métricas estudiadas verifica. Nombrarla y explicar qué ocurre si no se cumple.

6. Tres clases y una lista

Un sistema de priorización de mantenimiento clasifica 500 registros en tres categorías. Su matriz de confusión, con las filas por clase real y las columnas por clase predicha, es:

	urgente	programada	sin acción	Total
urgente	18	14	8	40
programada	10	46	24	80
sin acción	4	26	350	380

- Calcular precision, recall y F_1 **de cada clase**, tratándola como positiva y a las otras dos como negativas.
- Calcular F_1 micro, F_1 macro y F_1 ponderada. Verificar que la primera coincide con el accuracy y explicar por qué.
- Las tres cifras describen el mismo clasificador. Explicar qué mide la distancia entre ellas y cuál corresponde reportar si el objetivo del sistema es no dejar pasar ningún caso urgente.
- El mismo sistema, operado como lista priorizada, ordena veinte registros de mayor a menor puntaje de urgencia. Las etiquetas reales, en ese orden, son

1, 1, 0, 1, 0, 1, 0, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 0

Calcular precision@5, precision@10 y precision@20, y los recall correspondientes.

- El equipo de mantenimiento puede atender cinco registros por turno. Indicar qué cifra del inciso (d) le sirve para decidir si conviene ampliar esa capacidad, y qué le diría.

7. Análisis crítico de código

El fragmento siguiente ejecuta sin errores y produce la salida que se muestra.

```
import numpy as np, pandas as pd
from sklearn.linear_model import LogisticRegression as RL
from sklearn.model_selection import train_test_split as tts
from sklearn.metrics import roc_auc_score, accuracy_score, confusion_matrix
```

```
# Un incumplimiento cuesta en promedio 4000 USD de capital no recuperado.
# Rechazar a un cliente que habria pagado cuesta 300 USD de margen perdido.
d = pd.read_csv("riesgo_credito.csv")
d["hist_atrasos"] = (d.historial_credicio == "con atrasos").astype(int)
d["hist_sin"] = (d.historial_credicio == "sin historial").astype(int)
d["log_monto"] = np.log(d.monto_solicitado_usd) - np.log(10_000)
d["edad_c"] = d.edad_anios - 38

atr = ["cuota_ingreso", "hist_atrasos", "hist_sin", "consultas_buro_12m",
       "antiguedad_laboral_anios", "tiene_garantia", "edad_c", "log_monto"]
X, y = d[atr].to_numpy(float), d.incumplio.to_numpy()
Xtr, Xte, ytr, yte = tts(X, y, test_size=.30, random_state=42, stratify=y)

m = RL(penalty=None, max_iter=5000).fit(Xtr, ytr)
p = m.predict_proba(Xte)[:, 1]

print(f"AUC-ROC: {roc_auc_score(yte, p):.3f}")
print(f"accuracy: {accuracy_score(yte, p >= .5):.3f}")
tn, fp, fn, tp = confusion_matrix(yte, p >= .5).ravel()
print(f"matriz de confusion: TN={tn} FP={fp} FN={fn} TP={tp}")
print(f"costo total: {fn * 4000 + fp * 300:,}")
```

```
AUC-ROC: 0.806
accuracy: 0.827
matriz de confusion: TN=893 FP=45 FN=163 TP=99
costo total: 665,500
```

Conclusión del analista. El modelo alcanza un AUC de 0,806 y clasifica correctamente el 82,7 % de las solicitudes. El sistema queda aprobado para su puesta en producción.

Responder las tres preguntas del formato de evaluación de la asignatura:

1. **Análisis crítico.** Identificar y explicar qué falencia conceptual o metodológica presenta el flujo de trabajo, a partir del código y de las salidas.
2. **Impacto.** Explicar cómo afecta esa falencia al funcionamiento del sistema y qué consecuencias tiene sobre el resultado final.
3. **Propuesta de corrección.** Indicar cuál sería la corrección adecuada.

Bibliografía sugerida

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer. § 4.4.2, para la matriz de confusión, la sensibilidad y la especificidad, y la construcción de la curva ROC.

Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3.^a ed.). O'Reilly. **Capítulo 3**, para precision y recall, el compromiso entre ambas al mover el umbral, y la comparación entre las dos curvas.

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. Referencia canónica del análisis ROC, con la construcción eficiente de la curva y las propiedades del AUC que sostienen los ejercicios 3 y 4.

Elkan, C. (2001). The foundations of cost-sensitive learning. *Proceedings of the 17th International Joint Conference on Artificial Intelligence*, 973–978. Fuente de la deducción del ejercicio 5.