

Ejercicios — Regresión lineal y evaluación de modelos de regresión

Machine Learning

Notación

La de la asignatura. n observaciones, p atributos, $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$ la matriz que reúne los atributos con la columna de unos en primer lugar, $\boldsymbol{\beta} = (\beta_0, \dots, \beta_p)^\top$, $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$, $\hat{e}_i = y_i - \hat{y}_i$, $J(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2$.

1. Lineal, ¿en qué?

Decidir cuáles de los modelos siguientes son lineales **en los parámetros** y, por lo tanto, ajustables por mínimos cuadrados ordinarios sin transformación previa. Para los que no lo son, indicar si alguna transformación de la respuesta o de los atributos los convierte en tales.

- a. $\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2$
- b. $\hat{y} = \beta_0 + \beta_1 \log x$
- c. $\hat{y} = \beta_0 x^{\beta_1}$
- d. $\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2$
- e. $\hat{y} = \frac{1}{\beta_0 + \beta_1 x}$
- f. $\hat{y} = \beta_0 + \beta_1 \sin(\omega x)$, con ω conocido

2. Variables categóricas y codificación *one-hot*

Un atributo categórico no entra directamente en la matriz $\mathbf{X}$: sus valores son etiquetas, no números. Codificarlos con enteros arbitrarios —**Centro** = 1, **Norte** = 2, **Este** = 3— sería incorrecto, porque impondría un orden y unas distancias que la variable no tiene: el modelo leería que **Este** está al doble de **Norte** respecto de **Centro**.

La codificación habitual es la **one-hot** (*one-hot encoding*, o codificación por variables indicadoras): cada nivel de la categórica pasa a ser una columna binaria que vale 1 cuando la observación pertenece a ese nivel y 0 en caso contrario. Con tres zonas se agregan tres columnas y cada fila tiene exactamente un 1 entre ellas —de ahí el nombre—. Esa última propiedad, que hace transparente la codificación, es también el origen del problema que el ejercicio examina.

Un conjunto de seis observaciones registra la superficie de un local (en m²) y su zona, que toma tres valores: **Centro**, **Norte** y **Este**.

i	superficie	zona
1	120	Centro
2	85	Norte
3	200	Este
4	150	Centro
5	90	Este

i	superficie	zona
6	110	Norte

- Escribir la matriz $\mathbf{X}$ que resulta de incluir el intercepto, la superficie y la codificación one-hot completa de la zona, es decir, **una columna indicadora por cada zona**.
- Verificar que esa matriz no tiene rango completo, exhibiendo la combinación lineal que lo impide.
- Escribir la matriz correcta tomando **Centro** como categoría de referencia, y explicar qué representa entonces el coeficiente de la indicadora de **Norte**.
- Indicar cuántas columnas tiene la matriz de un modelo con q atributos numéricos y una categórica de m niveles, con intercepto.

3. Leer una tabla de coeficientes

La tabla siguiente corresponde a un modelo de precio de vivienda ajustado sobre 1460 observaciones. La respuesta está en dólares y las superficies, en pies cuadrados.

Atributo	$\hat{\beta}_j$	$SE(\hat{\beta}_j)$	t	p
Intercepto	-674 889	84 804	-7,96	< 0,001
Superficie habitable	50,54	2,57	19,68	< 0,001
Superficie de sótano	28,86	2,89	10,00	< 0,001
Superficie de garaje	18,54	10,31	1,80	0,072
Garaje (autos)	10 119	3047	3,32	0,001
Año de construcción	303,04	44,57	6,80	< 0,001
Calidad general (1-10)	20 442	1156	17,69	< 0,001

- Redactar la interpretación del coeficiente de la superficie habitable, con sus unidades y con la cláusula que lo condiciona.
- El coeficiente de la superficie de garaje tiene $p = 0,072$. Discutir tres lecturas posibles de ese valor y cuál es la información adicional que permitiría decidir entre ellas.
- El intercepto vale -674 889 dólares. ¿Es esto un defecto del modelo?
- ¿Cuál de las dos variables de garaje conviene conservar si el objetivo es predecir? ¿Y si el objetivo es explicar?

4. Métricas, a mano

Un modelo produce las predicciones siguientes sobre seis observaciones de prueba:

y_i	10	12	15	20	8	100
$\hat{y}_i$	12	11	18	17	10	70

- Calcular MAE, MSE, RMSE y R^2 .
- La sexta observación tiene un error de 30. Calcular qué proporción del MSE aporta ella sola y qué proporción del MAE, y explicar a qué se debe la diferencia.
- Explicar qué mide cada una de las cuatro métricas y qué pregunta responde. Justificar por qué el R^2 depende tanto del conjunto de datos sobre el que se calcula como del modelo que se evalúa.
- La sexta observación corresponde a un cliente corporativo cuyo consumo es veinte veces el de los demás. Indicar qué métrica corresponde reportar si un error grande cuesta desproporcionadamente más que varios errores chicos, y cuál si el costo del error es proporcional a su magnitud.

5. Mínimos cuadrados ponderados

Se reemplaza el costo por $J_{\mathbf{W}}(\beta) = (\mathbf{y} - \mathbf{X}\beta)^\top \mathbf{W}(\mathbf{y} - \mathbf{X}\beta)$, con $\mathbf{W}$ diagonal de elementos positivos $w_1, \dots, w_n$.

- Derivar $\hat{\beta}_{\mathbf{W}} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{y}$.
 - Interpretar w_i : ¿qué significa asignarle a una observación un peso diez veces mayor?
 - Un conjunto de datos registra el consumo promedio de m_i edificios agregados en la fila i . Indicar qué pesos corresponden y por qué.
 - Verificar que con $\mathbf{W} = \mathbf{I}$ se recupera el estimador ordinario.
-

Bibliografía sugerida

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer. **Capítulo 3** —§ 3.1 a § 3.3— para la formulación del modelo lineal, la codificación de variables categóricas y la lectura de la tabla de coeficientes. Los ejercicios conceptuales del final del capítulo complementan a esta serie.

Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning*. Springer. § 3.2, para las propiedades del estimador de mínimos cuadrados y su extensión al caso ponderado.